

判別分析と特徴空間

潜在空間

本谷 秀堅

名古屋工業大学


線形
教師あり

復習: 主成分分析

目的:

分散が大きくなる
方に直次元を
選ぶ

- ・線形
- ・教師なし.



主成分分析

主成分分析

高次元データ分布を低次元空間に射影して近似する（教師なし）

主成分分析

高次元空間におけるデータの分布を最も良く近似する線形部分空間を求める。

近似の善し悪しを下記の基準で測る

- 分散最大基準
- 平均二乗誤差最小基準

準備

- D 次元データの集合 $\mathcal{D} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$
- データの平均 \mathbf{m}

$$\mathbf{m} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$

- $d (< D)$ 次元部分空間の正規直交基底, $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_d\}$
- d 次元部分空間への $D \times d$ 変換行列, \mathbf{A}

$$\mathbf{A} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_d].$$

- 正規直交基底なので次式が成立する

$$\mathbf{v}_i^\top \mathbf{v}_j = \begin{cases} 1, & (i = j) \\ 0, & (i \neq j) \end{cases}, \quad \mathbf{A}^\top \mathbf{A} = \mathbf{I}.$$

- D 次元データ \mathbf{x}_i を d 次元ベクトル \mathbf{y}_i へと変換:

$$\mathbf{y}_i = \mathbf{A}^\top \mathbf{x}_i$$

行列 A による射影 (手書き)

分散最大基準: 準備

- d 次元ベクトルへの変換後のデータ集合, $\mathcal{Y} = \{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N\}$
- \mathcal{Y} の平均, $\tilde{\mathbf{m}}$

$$\tilde{\mathbf{m}} = \frac{1}{N} \sum_{i=1}^N \mathbf{y}_i = \mathbf{A}^\top \mathbf{m}$$

- 射影後の分散, $\tilde{\sigma}^2(\mathbf{A})$, は次式のとおり:

$$\tilde{\sigma}^2(\mathbf{A}) = \frac{1}{N} \sum_{i=1}^N (\mathbf{y}_i - \tilde{\mathbf{m}})^\top (\mathbf{y}_i - \tilde{\mathbf{m}}) = \text{tr}(\mathbf{A}^\top \Sigma \mathbf{A})$$

ただし, Σ は \mathcal{D} の共分散行列

$$\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \mathbf{m})(\mathbf{x}_i - \mathbf{m})^\top$$

前項の導出

$$\begin{aligned}\frac{1}{N} \sum_i (\mathbf{y}_i - \tilde{\mathbf{m}})^T (\mathbf{y}_i - \tilde{\mathbf{m}}) &= \\ &= \frac{1}{N} \sum_i \text{tr} (\mathbf{A}^T (\mathbf{x} - \mathbf{m}) (\mathbf{A}^T (\mathbf{x} - \mathbf{m}))^T)\end{aligned}$$

=

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \text{tr}(\mathbf{A} \mathbf{x} \mathbf{x}^T), \quad \frac{\partial}{\partial \mathbf{A}} \text{tr}(\mathbf{A} \mathbf{B}) = \mathbf{B}^T$$

分散最大基準による主成分分析の導出


$\mathbf{A}^\top \mathbf{A} = \mathbf{I}$ を満たしつつ、分散 $\tilde{\sigma}(\mathbf{A})$ を最大にする \mathbf{A} を求めたい

$$J(\mathbf{A}) = \text{tr}(\mathbf{A}^\top \Sigma \mathbf{A}) - \text{tr}((\mathbf{A}^\top \mathbf{A} - I)\mathbf{L})$$

ただし \mathbf{L} は $d \times d$ の対角行列。上式を最大にする \mathbf{A}^* は次の通りで、 $\tilde{\sigma}^2$ の最大値は $\lambda_1 + \lambda_2 + \dots + \lambda_d$ になる。


$$\mathbf{A}^* = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d], \quad \mathbf{L}^* = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_d \end{bmatrix}$$

すなわち、共分散行列 Σ の固有値を大きい順に d 個選び、対応する d 個の固有ベクトルが張る空間が投影後の分散を最大にする。



$$\|w\| = 1$$

$$w^T x = \|x\| \cos \theta$$



單點統計 分散: $\text{trace}(A^T \Sigma A)$

$$= \text{trace}(\boxed{A^T} \boxed{\Sigma} \boxed{A})$$

$$\boxed{\Sigma} = \frac{1}{N} \sum_{i=1}^N (x_i - m)(x_i - m)^T$$

→ 空間 2D
變分散

前項の導出

$$J(\mathbf{A}) = \underbrace{\text{等価係数}}_{\text{等価係数の等価}} \text{tr}(\mathbf{A}^\top \Sigma \mathbf{A}) - \underbrace{\text{等価係数}}_{\text{等価係数の等価}} \text{tr}((\mathbf{A}^\top \mathbf{A} - I)L)$$

$$\frac{\partial J(\mathbf{A})}{\partial \mathbf{A}} = \cancel{2\Sigma A} = AL = 0$$

L = $\begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix}$
ラムダシュー係数

ただし下記を利用する

$$\Sigma A = AL$$

$$\boxed{\square \square} = \boxed{\square}^2$$

$$\frac{\partial}{\partial X} \text{tr}(X^T Y X) = (Y + Y^T)X$$

$$A = \begin{bmatrix} w_1 & w_2 \end{bmatrix}$$

上記より次式が成り立つ

$$A^T \Sigma A = L$$

従って

$$\Sigma A = AL$$

左から A^T

$$\max_A \tilde{\sigma}^2(A) = \max_A \underbrace{\text{等価係数}}_{\text{等価係数の等価}} \left\{ \text{tr} (A^T \Sigma A) \right\} =$$

$$\Sigma \boxed{w} = \lambda \boxed{w}$$

Σ の固有ベクトル w
+ $\text{tr}(A^T \Sigma A)$ を極大化する。

$$= \max_A \{ \text{trace}(L) \}$$

$$= \max \{ \lambda_1 + \lambda_2 + \dots + \lambda_d \}$$

主成分の次元
(我々が勝手に選める)

固有値を
大きい順に
d個選ぶ。

平均二乗誤差最小基準：準備

- データ \mathbf{x}_i ($i = 1, 2, \dots, N$) を、点 \mathbf{x}_0 を通る d 次元部分空間に正射影した後の座標は次式のとおり：

$$\mathbf{A}\mathbf{y}_i + \mathbf{x}_0 = \mathbf{A}\mathbf{A}^\top(\mathbf{x}_i - \mathbf{x}_0) + \mathbf{x}_0$$

- 射影前後の差を表すベクトルは次のとおり

$$(\mathbf{A}\mathbf{y}_i + \mathbf{x}_0) - \mathbf{x}_i = (\mathbf{A}\mathbf{A}^\top - \mathbf{I})(\mathbf{x}_i - \mathbf{x}_0)$$

- $\mathbf{Q} = \mathbf{I} - \mathbf{A}\mathbf{A}^\top$ と置く。平均二乗誤差, ϵ^2 , は次のとおり

$$\epsilon^2(\mathbf{A}, \mathbf{x}_0) = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \mathbf{x}_0)^\top \mathbf{Q} (\mathbf{x}_i - \mathbf{x}_0)$$

演習

ϵ^2 の式を導出せよ。

平均二乗誤差最小基準

二乗誤差を最小にするためには、点 x_0 は次式を満たさなければいけない。

$$\frac{\partial \epsilon^2}{\partial x_0} = \frac{1}{N} \sum_{i=1}^N (2\mathbf{Q}x_0 - 2\mathbf{Q}x_i) = \mathbf{0}$$

よって

$$\mathbf{Q}x_0 = \mathbf{Q}\mathbf{m}.$$

このとき次式が成立する（分散最大化の問題と同じ問題に帰着される）

$$\epsilon^2(\mathbf{A}) = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \mathbf{m})^\top \mathbf{Q} (\mathbf{x}_i - \mathbf{m}) = \text{tr} \Sigma - \text{tr} (\mathbf{A}^\top \Sigma \mathbf{A})$$

前項の導出

$$\begin{aligned}\epsilon^2(\mathbf{A}) &= \frac{1}{N} \sum_i (\mathbf{Q}(\mathbf{x}_i - \mathbf{m}))^T (\mathbf{Q}(\mathbf{x} - \mathbf{m})) \\ &= \frac{1}{N} \sum_i (\mathbf{x}_i - \mathbf{m})^T \mathbf{Q}(\mathbf{x}_i - \mathbf{m}) \\ &= \frac{1}{N} \sum_i (\mathbf{x}_i - \mathbf{m})^T (\mathbf{I} - \mathbf{A}\mathbf{A}^T)(\mathbf{x}_i - \mathbf{m}) \\ &= \frac{1}{N} \sum_i \text{tr}(\mathbf{x}_i - \mathbf{m})(\mathbf{x}_i - \mathbf{m})^T - \text{tr}(\mathbf{A}^T(\mathbf{x}_i - \mathbf{m})(\mathbf{x}_i - \mathbf{m})^T \mathbf{A}) \\ &= \text{tr}(\Sigma) - \text{tr}(\mathbf{A}^T \Sigma \mathbf{A})\end{aligned}\tag{1}$$

平均二乗誤差最小基準

$\mathbf{A}^\top \mathbf{A} = \mathbf{I}$ を満たしつつ平均二乗誤差を最小にするには、 $\text{tr}(\mathbf{A}^\top \Sigma \mathbf{A})$ を最大にすれば良い。分散最大基準と同じ。

すなわち、共分散行列 Σ の固有値を大きい順に d 個選び、対応する d 個の固有ベクトルが張る部分空間に正射影するとき、平均二乗誤差が最小になる。

- フォルダ 作成.
- Moodle に PDF upload

→
4/17

判別分析



教師による学習

① 映像 (mapping)

② 特徴抽出


③ 潜在表現 (latent representation)

Fisher判別分析

Fisher判別分析





高次元データ分布を識別に適した低次元空間に射影して近似する（教師あり）


例




どの向きに射影すれば赤と青を分離できるか？

例





線形分離可能域



$\frac{\text{クラス間距離}}{\text{クラス内変動}} \rightarrow \max$



Fisher判別分析：準備

クラス内変動とクラス間変動の比を最大にする1次元空間を求める

- クラス ω_1 と ω_2 に属する学習データの集合を \mathcal{X}_1 と \mathcal{X}_2 で表す。
- それぞれの学習データ数を $|\mathcal{X}_1| = N_1$, $|\mathcal{X}_2| = N_2$ で表す。
- 全体の平均を \mathbf{m} で表す ($N = N_1 + N_2$):

$$\mathbf{m} = \frac{1}{N} \sum \mathbf{x}$$

- それぞれの学習データの平均を \mathbf{m}_i で表す:

$$\mathbf{m}_1 = \frac{1}{N_1} \sum_{\mathbf{x} \in \mathcal{X}_1} \mathbf{x}, \quad \mathbf{m}_2 = \frac{1}{N_2} \sum_{\mathbf{x} \in \mathcal{X}_2} \mathbf{x}$$

- クラス ω_i の変動を表す変動行列を \mathbf{S}_i で表す:

$$\mathbf{S}_i = \sum_{\mathbf{x} \in \mathcal{X}_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^\top$$

↑
クラス i の
データ
↓
クラス i の
平均

Fisher 判別分析：準備

- クラス内変動行列 (within-class scatter matrix), S_W

$$S_W = S_1 + S_2 = \sum_{i=1}^2 \sum_{x \in \mathcal{X}_i} (x - m_i)(x - m_i)^\top$$

- クラス間変動行列 (between-class scatter matrix), S_B

$$S_B = \sum_{i=1}^2 N_i (\overbrace{m_i}^{\substack{\text{各クラスの平均}}\atop\uparrow} - \overbrace{m}^{\substack{\text{全体の平均}}\atop\uparrow}) (m_i - m)^\top = \frac{N_1 N_2}{N} (m_1 - m_2)(m_1 - m_2)^\top$$

- $D \times 1$ 変換ベクトル, w

$$y = w^\top x$$

- $x \in \mathcal{X}_i$ を変換して得られた y の集合 \mathcal{Y}_i

$$\boxed{y} = \boxed{w^\top} \boxed{x}$$

クラス内・外の差異に意味

Fisher判別分析：準備

- 変換後の平均, \tilde{m}_i :

$$\tilde{m}_i = \frac{1}{N_i} \sum_{y \in \mathcal{Y}_i} y = \frac{1}{N_i} \sum_{x \in \mathcal{X}_i} w^\top x = w^\top m_i$$

- 変換後のクラス内変動 \tilde{S}_W

$$\tilde{S}_W = \tilde{S}_1 + \tilde{S}_2 = \sum_{i=1}^2 \sum_{y \in \mathcal{Y}_i} (y - \tilde{m}_i)^2 = w^\top S_W w$$

- 変換後のクラス間変動 \tilde{S}_B

$$\tilde{S}_B = \sum_{i=1}^2 N_i (\tilde{m}_i - \tilde{m})^2 = \frac{N_1 N_2}{N} (\tilde{m}_1 - \tilde{m}_2)^2 = w^\top S_B w$$

Fisher 判別分析

- Fisher 判別基準 (クラス内変動・クラス間変動比)

$$J(\mathbf{w}) = \frac{\tilde{S}_B}{\tilde{S}_W} = \frac{\mathbf{w}^\top \mathbf{S}_B \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}}$$

分子分母に
スケール不変性

を最大化

Fisher 判別基準を最大にする \mathbf{w} は次式で与えられる

$$\mathbf{w} \propto \mathbf{S}_W^{-1} (\mathbf{m}_1 - \mathbf{m}_2)$$

$$\mathbf{w} = \boxed{\mathbf{S}_W^{-1}} \left(\boxed{\mathbf{m}_1} - \boxed{\mathbf{m}_2} \right)$$

演習

Fisher 判別基準を最大にするベクトル w の式を導出せよ。

- スケーリング性があるから $\frac{w^T S_w w}{w^T S_B w}$ を最大にする。
 $w^T S_B w$ を最小にする。

$$\textcircled{1} \quad J(w) = w^T S_B w - \lambda (w^T S_w w - 1) \rightarrow \max_{w \in \mathbb{R}^n}$$

$$\boxed{\frac{1}{2} \frac{dJ}{dw} = S_B w - \lambda S_w w = 0}$$

$S_W^{-1} S_B$ の最大固有値を λ_1 とおくと $J(w)$ の最大値は λ_1 になる。

内積 $(m_1 - m_2)^T w$ がスカラであることに注意すると次式を得ることが出来る

$$w \propto S_W^{-1}(m_1 - m_2)$$

$$\vec{S}_B w = \lambda \vec{S}_w w$$

$$\square \square = \square \square$$

$$\vec{S}_w \vec{S}_B w = \lambda w$$

必要条件

最大固有値に対する

最高の $w \Rightarrow \vec{S}_w \vec{S}_B w$ 固有ベクトル

$$\frac{w^T \vec{S}_B w}{w^T \vec{S}_w w} = \frac{w^T \lambda \vec{S}_w w}{w^T \vec{S}_w w} = \lambda$$



最大固有値
が 2 で 進みます。

$$\sum_B w = \lambda \sum_W w$$



$$\sum_B = \frac{N_1 N_2}{N^2} (m_1 - m_2) (m_1 - m_2)^T$$

$$\lambda \sum_W w = \frac{N_1 N_2}{N} (m_1 - m_2) (m_1 - m_2)^T w$$





$$= \square (m_1 - m_2)$$

$$\frac{m}{\pi} \left[S_w \right] \frac{m}{\pi} = m \left[\frac{1}{(m_1 - m_2)} \right]$$

$$\boxed{\frac{m}{\pi} \propto S_w^{-1} (m_1 - m_2)}$$

例題の解答




$$\begin{aligned} \mathbf{m}_1 &= \begin{bmatrix} 5.04 \\ 1.12 \end{bmatrix}, \quad \mathbf{S}_1 \propto \begin{bmatrix} 2.03 & 1.10 \\ 1.10 & 2.22 \end{bmatrix}, \quad \mathbf{m}_2 = \begin{bmatrix} -5.00 \\ -1.00 \end{bmatrix}, \quad \mathbf{S}_2 \propto \begin{bmatrix} 1.88 & 0.93 \\ 0.93 & 2.04 \end{bmatrix} \\ \mathbf{w} &\propto \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) = \begin{bmatrix} 3.07 \\ -0.97 \end{bmatrix} \end{aligned}$$

識別器と識別に有利な特徴

準備：データの分布

例：あやめの種類を花の形で識別したい



<https://atmarkit.itmedia.co.jp/ait/articles/2206/13/news032.html>

準備：データの分布

例：あやめのデータ

列番号	1	2	3	4	目的変数↓
説明変数→	Sepal Length	Sepal Width	Petal Length	Petal Width	target
行番号↓	がく片の長さ(cm)	がく片の幅(cm)	花びらの長さ(cm)	花びらの幅(cm)	あやめの種類
0	5.1	3.5	1.4	0.2	0
1	4.9	3.0	1.4	0.2	0
2	4.7	3.2	1.3	0.1	0
3	4.6	3.1	1.5	0.2	0
4	5.0	3.6	1.4	0.2	0
5	5.4	3.9	1.7	0.4	0
6	4.6	3.4	1.4	0.3	0
7	5.0	3.4	1.5	0.2	0
8	4.4	2.9	1.4	0.2	0
49	5.0	3.3	1.4	0.2	0
50	7.0	3.2	4.7	1.4	1
51	6.4	3.2	4.5	1.5	1
52	6.9	3.1	4.9	1.5	1
53	5.5	2.3	4.0	1.3	1
54	6.5	2.8	4.6	1.5	1
55	5.7	2.8	4.5	1.3	1
56	6.3	3.3	4.7	1.6	1
57	4.9	2.4	3.3	1.0	1

X

$$x_0 \dots x_2 \dots y_0 = 0$$

$$y_2 = 0$$

あやめの種類
「0」


setosa



$$y_{55} = 1$$


<https://atmarkit.itmedia.co.jp/ait/articles/2206/13/news032.html>

準備：データの分布




準備：データの分布

データの分布（教師あり）




データの分布（教師なし）



(最も複雑)
/ パラメータ
(これから学習を深める)

準備：線形識別器の教師あり学習

準備：ニューラルネットワークの「ユニット」



ユニットの入出力

- 入力： $\mathbf{x} = (x_1, x_2, \dots,)^\top$
- 出力： $y = f(u)$
 - まず重みとの内積+定数を計算： $u = w_1x_1 + w_2x_2 + \dots + b = \mathbf{w}^\top \mathbf{x} + b$
 - 次に活性化関数： $f(u) = f(\mathbf{w}^\top \mathbf{x} + b)$


$$P(y=1 | x) = \frac{1}{1 + \exp(-a)}$$

$$a = w^T x + w_0$$

口以 274, 7 例

準備：線形識別器の教師あり学習

例：あやめの識別タスク



準備：線形識別器の教師あり学習

wは 損失が最小になるように
(目的の対象を含む) 用采。)

例：あやめの識別器の学習（2クラス）

損失関数（交差エントロピー）：
 $P(y|x) = \pi^y (1-\pi)^{1-y}$
 $\log P = y \log \pi + (1-y) \log (1-\pi)$


$$\sum_{i=1}^N y_i \log f(\omega_1 x_{i,1} + \omega_2 x_{i,2} + \omega_0) + (1 - y_i) \log(1 - f(\omega_1 x_{i,1} + \omega_2 x_{i,2} + \omega_0))$$

- $x_{i,1}$: i 番目のデータの「がく片の長さ」
- $x_{i,2}$: i 番目のデータの「がく片の幅」
- y_i : i 番目のデータの「あやめの種類」(0 or 1)
- $f(\cdot)$: データ x が「アヤメ 1」のものである事後確率の回帰

シグモイド関数

準備：線形識別器の教師あり学習


例：あやめの識別タスク（再掲）




$$u = w_1 x_1 + w_2 x_2 + b$$

準備：線形識別器の教師あり学習

w_0, w_1, w_2 を使って
青色赤色を表す
(1) 重み w_1, w_2 との積和でスカラ u に、(2) シグモイド関数で z に 映すに




$$u = w_1 x_1 + w_2 x_2 + b$$




準備：線形識別器の教師あり学習

$z \leq 0.5$ で識別



準備：線形識別器の教師あり学習

$z = f(u) \leq 0.5$ で識別




$u = \mathbf{w}^\top \mathbf{x} + b = 0$ が識別境界

準備：特徴空間への写像

$u = \mathbf{w}^\top \mathbf{x} + b$ のデータ \mathbf{x} から特徴 u への写像



誤別閾値への寫像



準備：特徴空間への写像

$u = \mathbf{w}^\top \mathbf{x} + b$ のデータ \mathbf{x} から特徴 u への写像


→ 特徴量



準備：特徴空間への写像


識別タスクに望ましい特徴量（参考：判別分析）

- クラス内変動に不变・鈍感
- クラス間変動に敏感




準備：特徴空間への写像

同一カテゴリであり続ける変換に対して鈍感・不变な特徴量が良い



準備：特徴空間への写像

計測値間に相関により同一カテゴリの分布が低次元に



準備：画像データ

画像データ


- 画素値の配列（高次元データ）
- 近傍の画素値間に強い関係（高次元空間中で低次元に分布）



157	153	174	168	150	152	129	151	172	161	155	156
156	182	163	74	75	62	33	17	116	210	180	154
180	180	50	14	54	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	157	251	237	299	239	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218



Diagram illustrating the 2D image data as a 28x28 grid of pixels, represented as a 1D array of 784 elements. A blue double-headed arrow at the top indicates the width of 28 pixels. A blue double-headed arrow on the right indicates the height of 28 pixels. Blue arrows point from the first few elements of the array back to the corresponding pixels in the image.

157	163	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	33	17	116	210	180	154
180	180	50	14	54	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	239	239	228	227	87	71	201
172	105	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218



準備：ニューラルネットワーク

シンプルな写像を繰り返して、最後に線形識別




特徴の線形化

線形識別器

準備：ニューラルネットワーク



例：ResNet34 (ImageNet で学習。1000 クラス識別)



シンプルな写像を繰り返して、最後に線形識別

準備：識別に適した画像特徴量


多クラス識別：最終層のユニットのひとつが「発火」



正解クラスの事後確率が最大

準備：識別に適した画像特徴量

見え方が変化しても同じユニットが発火



「おばあさん細胞」の発想

寄り道：ニューラルネットワークの発想

おばあさん細胞

文 A 5の言語版 ▾

目次 非表示

ページ ノート

閲覧 編集 腹歴を表示 ツール ▾

ページ先頭

出典: フリー百科事典『ウィキペディア (Wikipedia)』

概要

おばあさん細胞（おばあさんさいぼう、英: Grandmother cell、またはgnostic neuron）とは、その人のおばあさん、より一般的に言えば、複合的な特定の概念や対象物を表現している仮想的な細胞である^[1]。おばあさん細胞は、その人が自身のおばあさんの姿を見たり、声を聞くなどして感覚的に識別する際に活動する^[2]。おばあさん細胞という用語はジェローム・レトビンによる造語である。

反論

脚注

外部リンク



概要 [編集]

おばあさん細胞仮説を支持する初期の研究として、サルの下側頭皮質にある、手と顔に選択的に発火する視覚ニューロンに関する研究がある^{[3][4][5][6]}。しかし、果物や性器などのサルにとって重要な他の視覚対象に対して選択的に発火する細胞は見つかっていない。このことは、バナナなどの他のカテゴリーを識別するよりも、顔を識別する方がサルにとってより重要であるためと考えられている。加えて、サルが識別しなくてはならない他の視覚刺激に比べ、顔は全体的な特徴と細部が顔同士でよく似ているためと考えられている^[1]。

おばあさん細胞仮説を支持する最近の研究^{[7][8]}として、下側頭皮質の細胞は任意の視覚対象に対して非常に選択的に反応するように訓練できるということを示した研究が存在する。この性質はおばあさん細胞に求められる条件に合致したものである。加えて、ヒトの海馬にある細胞が個人の顔^[9]を含む、認識のカテゴリーに対して非常に選択的に反応する^{[10][11]}といった証拠が見つかっている。

準備：教師あり学習


正解ユニットが発火するように学習



同じカテゴリであり続ける変化に鈍感・不变

準備：教師あり学習

正解ユニットが発火するように学習



同じカテゴリであり続ける変化に鈍感・不变な**特徴量の獲得**